

Trabajo Práctico Minería de Datos

1. Diseñe un cuadro de doble entrada donde conecte las 9 etapas del proceso KDD con los insumos (datos de partida) y los productos (conocimiento/patrones) generados en cada una. Explique cómo un fallo u omisión en la etapa de "Preprocesado" impacta directamente en la validez del "Modelo Clasificador" final.
2. Elabore un diagrama jerárquico que demuestre por qué la Minería de Datos es una fase fundamental pero subordinada al proceso global de KDD. Argumente la veracidad de la siguiente afirmación basada en el texto: "Hacer Minería de Datos sin KDD es una operación algorítmica ciega; hacer KDD sin Minería de Datos es un proceso inconcluso".
3. Contraste la Minería de Datos vs. Estadística Clásica utilizando como ejes de comparación el nivel de automatización, el enfoque (exploratorio vs. confirmatorio) y la incorporación de la Inteligencia Artificial. Redacte un análisis crítico sobre el "segundo reto" del texto (el contraejemplo de la longevidad en Florida) para explicar por qué una correlación estadística significativa no equivale a una relación causa-efecto en la minería de datos.
4. Construya una tabla comparativa de tres columnas para delimitar el campo de acción de las siguientes tecnologías: Minería de Datos vs. Herramientas OLAP vs. Monitoreo. Utilice los siguientes criterios de diferenciación extraídos del documento:
 - o Generación de nueva información vs. navegación asistida.
 - o Naturaleza de los datos (estáticos/históricos vs. tiempo real/cambiantes).
 - o Dinámica de uso (descubrimiento proactivo vs. consulta del usuario).
5. Clasifique en un mapa conceptual las tareas: Agrupamiento/Clustering, Clasificación, Regresión, Modelado de Dependencias, Detección de Desviaciones, Condensación; bajo sus respectivos paradigmas de aprendizaje (supervisado/predictivo o no supervisado/descubrimiento).
6. Relacione las metas de predicción y descripción con los lenguajes de representación del conocimiento humano. Explique por qué, aunque las Redes Neuronales se consideran un método válido de minería de datos, sus estructuras de bajo nivel chocan con el criterio de "Lenguaje de alto nivel inteligible" exigido para el conocimiento descubierto en KDD.
7. Cree un árbol de decisiones de procedimientos académicos que vincule las causas de los "datos faltantes" (missing values) y "datos atípicos" (outliers) con sus respectivas soluciones técnicas permitidas en el texto (filtrar filas, discretizar, reemplazar valores por medias, segmentar por tuplas o ignorar mediante algoritmos robustos). Evalúe el impacto de sesgo que produce cada solución sobre el conjunto final.
8. Redacte un ensayo breve que interconecte las siguientes problemáticas críticas: la escalabilidad del hardware ante volúmenes masivos de datos, la granularidad del tiempo en las variables dinámicas y las implicaciones

éticas/legales de la pérdida de privacidad por la combinación corporativa de bases de datos de perfiles personales.

9. Realizar un cuadro comparativo exhaustivo entre las tres metodologías estándar de la industria para el descubrimiento de conocimiento y minería de datos:

- **KDD** (*Knowledge Discovery in Databases*)
- **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*)
- **SEMMA** (*Sample, Explore, Modify, Model, Assess*)

La tabla comparativa deberá estructurarse bajo los siguientes ejes analíticos:

- **Origen y Enfoque:** Contexto histórico de creación (académico vs. empresarial) y filosofía de diseño.
 - **Mapeo de Fases Equivalentes:** Demostrar visualmente cómo las fases técnicas (Preparación, Predicción y Análisis No Supervisado) se denominan y agrupan dentro de cada una de las tres metodologías.
 - **Iteración y Flexibilidad:** Evaluar la capacidad de cada ciclo de vida para retroceder ante el hallazgo de errores en los datos.
 - **Orientación al Negocio:** Determinar cuál de los tres marcos prioriza el alineamiento con los objetivos comerciales o de toma de decisiones estratégicas desde su etapa inicial.
-

Trabajo Práctico Integrador: Descubrimiento de Conocimiento (KDD) en el Fútbol Internacional

Objetivo General

Desarrollar un proyecto analítico completo aplicando las **9 etapas del proceso KDD** sobre un corpus de datos deportivos históricos, transitando desde el negocio/dominio hasta la evaluación de modelos de **Minería de Datos** (predictivos y descriptivos).

Enunciado y Consignas por Fases KDD

Fase 1: Comprensión del Dominio y Definición del Problema

Se debe asumir el rol de analistas analíticos para una federación deportiva o una cadena mediática.

- **Consigna:** Defina formalmente **dos objetivos de negocio**: uno orientado a la **predicción** (ej. anticipar qué selecciones tienen más probabilidad de ganar en instancias de eliminación directa basándose en goles históricos) y otro a la **descripción** (ej. caracterizar perfiles o clústeres de torneos/eras según su nivel de competitividad o efectividad de cara al gol).

Fase 2: Selección y Creación del Target Dataset

El conjunto de datos está fragmentado en tres archivos transaccionales con diferentes granularidades (goles individuales, partidos completos y series de penales).

- **Consigna:** Diseñe el esquema de un **tablón analítico único** (Data Mart). Determine qué entidades y llaves primarias/foráneas cruzará (ej. vincular Match_Results con Goal_Scorers a través del ID del partido o la combinación de fecha/equipos) para consolidar la información necesaria que responda a las metas de la Fase 1.

Fase 3: Preprocesamiento y Limpieza de Datos

Los datos deportivos reales sufren de ruido, inconsistencias temporales y datos faltantes históricos.

- **Consigna:** Documente y resuelva las siguientes problemáticas detectadas en el preprocesamiento:
 - o **Tratamiento de nulos/faltantes:** En partidos antiguos de Goal_Scorers, los minutos exactos del gol o si fue de penal (penalty) pueden venir vacíos. Evalúe qué estrategia de imputación o descarte penaliza menos la varianza de los datos.
 - o **Consistencia de nombres:** Controle anomalías en las cadenas de texto (ej. variaciones en nombres de países debido a cambios políticos históricos como URSS/Rusia, o codificaciones de caracteres especiales en apellidos de jugadores).
 - o **Datos atípicos (Outliers):** Identifique partidos con goleadas históricas extremas. Decida mediante criterios estadísticos si deben aislarse o mantenerse en el dataset según el impacto en el algoritmo de minería.

Fase 4: Transformación y Reducción de Datos

Los algoritmos de minería no operan de manera óptima sobre texto libre o fechas crudas.

- **Consigna:** Realice ingeniería de características (*feature engineering*):
 - o **Derivación temporal:** Convierta las fechas de los partidos en variables dinámicas organizadas por "Eras" (ej. Pre-guerra, Era Moderna, Era del VAR) o extraiga la estacionalidad (mes del año).
 - o **Agregación estructural:** Transforme las filas de goles individuales (Goal_Scorers) en métricas agregadas por partido (ej. cantidad de goles del equipo local en el primer tiempo, promedio de edad del goleador si estuviera disponible, o porcentaje de goles de jugada vs. penal).
 - o **Codificación:** Aplique técnicas de discretización o *One-Hot Encoding* para variables categóricas esenciales (como el continente o confederación del equipo).

Fase 5: Selección de la Tarea de Minería de Datos

- **Consigna:** En correspondencia con la Fase 1, formalice técnicamente las tareas analíticas. Para la meta predictiva se exigirá una tarea de **Clasificación Supervisada** (el target será el resultado: Victoria/Empate/Derrota). Para la meta descriptiva se exigirá una tarea de **Agrupamiento (Clustering)** o el descubrimiento de **Reglas de Asociación** (ej. identificar qué combinaciones de

países y minutos de juego suelen gatillar tandas de penales en Penalty_Shootouts).

Fase 6: Selección del Algoritmo y Proceso Analítico

- **Consigna:** Seleccione y justifique el uso de al menos dos algoritmos por tarea. Por ejemplo, contrastar un árbol de decisión (clasificador interpretable de alto nivel inteligible) frente a un método probabilístico como Naive Bayes para la predicción del ganador; y aplicar K-Means para la segmentación de partidos.

Fase 7: Minería de Datos

- **Consigna:** Ejecute el entrenamiento de los modelos implementando una partición estricta de datos de entrenamiento (*train*) y prueba (*test*) para evitar el sobreajuste (*overfitting*), uno de los principales retos destacados en la teoría.

Fase 8: Interpretación y Evaluación de Patrones

Los números arrojados por el software deben ser auditados bajo la lupa del conocimiento humano.

- **Consigna:** Evalúe los modelos utilizando matrices de confusión, precisión, *recall* y siluetas de clústeres. Responda críticamente: ¿El patrón descubierto aporta conocimiento novedoso o es una obviedad del dominio (ej. *"los equipos que meten más goles ganan más partidos"*)? ¿Se detectan correlaciones ilegítimas que confundan causalidad con casualidad?

Fase 9: Consolidación del Conocimiento Descubierto

- **Consigna:** Elabore el informe ejecutivo final enfocado en el despliegue. Diseñe cómo se presentará este conocimiento mediante un tablero visual y describa la estrategia para mantener el sistema actualizado con los partidos que se disputen el próximo año (Fase de Monitorización).
-

Entregables Requeridos

1. **Código fuente documentado:** Scripts limpios donde se aprecien los pasos secuenciales de la transformación de los tres archivos .csv.
2. **Bitácora de Preprocesamiento:** Un documento detallando exactamente cuántos registros nulos o atípicos encontraron y cuál fue la regla técnica utilizada para solucionarlos.
3. **Informe de Resultados y Contraste:** Explicación en lenguaje de alto nivel de los patrones descubiertos, defendiendo por qué el modelo elegido cumple con las restricciones de eficiencia y privacidad del KDD.